

RFPS 方法说明

用轻量 Fisher 不变两点响应筛选因子化偏好程序对

方法版本 5.0（固定弧长修订）

2026 年 7 月 28 日

摘要

本文给出 RFPS (*Response-Field Program-pair Search*, 响应场程序对搜索) 的最小版本。搜索变量仍是两个短程序 $C = (f, g)$: g 决定如何构造和加权偏好对, f 决定每个偏好对产生什么损失; 变异时每次只改一个程序, 但筛选和训练始终评价完整组合。为了在真实训练前发现行为近似重复的组合, 筛选器需要比较候选如何重新分配同一组 rollout 的概率质量, 而不能比较某组任意坐标下的梯度数值。经验分布可以用概率、log-weight 或平方根概率表示; 若描述符随这种表示改变, “行为相近”便不是程序对自身的性质。因此我们把固定 rollout 上的经验分布看作统计流形, 并要求描述符满足重参数化不变、等信息距离探测和跨点可比三项条件。这些条件分别给出 Fisher 单位自然梯度 d_0 、固定 Fisher-Rao 弧长 $\ell = 0.03$ 的闭式指数映射, 以及把第二点方向移回起点的闭式平行移动。在新点重新计算方向并移回后得到 d_1 ; 把 (d_0, d_1) 拼接, 便得到统一的行为描述符。

最终方法只保留使上述三项条件成立所需的三个几何操作: Fisher 单位化、一次指数映射和一次平行移动; 双锚点、30/60 步积分、第三个流点、曲率残差、自适应步长、ESS 通道、Gram 通道、随机投影和额外的多样性父代模块全部删除。两组独立 probe 的离线消融表明: 两点方向承担主要预测收益; 在相同两次求导预算下, Fisher 构造相较坐标依赖的欧氏两点基线在 scratch、warm-start 和外部候选集上一致持平或小幅提高相关性, 且没有增加危险近邻的误跳过率。描述符只用于软分配训练预算; 候选的 fitness 仍只来自真实 on-policy 训练。

目录

1	问题与最终方法	2
1.1	为什么仍然搜索两个程序	2
1.2	筛选对象: 分布上的行为, 而非坐标中的数值	3
1.3	一句话版本	3
1.4	旧版哪些组件被删除	4
2	预备知识: 从表型等价到统计流形	4
2.1	参考 rollout bank	4
2.2	完整程序对诱导的损失	4
2.3	经验 log-weight 坐标	5
2.4	为什么不变度量必须是 Fisher-Rao	5

1 问题与最终方法	2
2.5 完整程序对的 Fisher 单位自然梯度	6
3 轻量 Fisher 不变两点响应	6
3.1 第一点：候选的初始方向	6
3.2 固定弧长的一次闭式指数映射	7
3.3 把第二方向移回共同切空间	7
3.4 统一描述符与距离	7
3.5 描述符计算过程	8
4 用描述符分配真实训练预算	8
4.1 代表集与最近邻	8
4.2 软筛选而非硬删除	9
4.3 搜索循环	9
5 与已有方法及廉价基线的区别	9
5.1 相关工作的边界	9
5.2 与更直接的梯度基线比较	9
5.3 创新性边界	10
6 最小化消融证据	11
6.1 设置与指标	11
6.2 主结果	11
6.3 每个旧组件是否有独立贡献	12
6.4 弧长与探针选择	12
7 搜索空间覆盖与程序合法性	13
8 计算代价	13
9 实现边界与失败保护	13
10 符号表	14
11 结论	14

1 问题与最终方法

1.1 为什么仍然搜索两个程序

一个偏好训练目标通常同时包含两个决定：

- **比较什么：**如何从 rollout 中选出偏好对、如何确定正负样本、如何加权；记为程序 g ；




图 1: 最终 RFPS 只有一条计算链。虚拟扰动不更新网络参数，也不生成新的 rollout。

- **怎样惩罚：**给定一对轨迹后，如何把 log-probability、目标值和集合统计量组合成标量损失；记为程序 f 。

因此候选基因型写成 $C = (f, g)$ 。每次只变异 f 或 g ，可以让大模型只生成一个短程序；但候选行为不是 f 与 g 的两个分数之和，而是二者组合后诱导的完整损失。RFPS 因而采用“因子化生成、联合表型评价”：生成问题被拆小，交互作用不被拆掉。

1.2 筛选对象：分布上的行为，而非坐标中的数值

我们的目的不是预测候选的最终 fitness，而是在真实训练前回答一个更窄的问题：**两个完整程序对是否会在相同局部状态下诱导近似相同的训练压力？**在固定 rollout bank 上，这个压力表现为候选希望增加哪些轨迹的相对概率、降低哪些轨迹的相对概率。因此程序对的廉价表型应定义在经验分布 q 上，而不是定义在实现所选的数组坐标上。

这个区分很重要。同一个严格为正的经验分布既可写成概率 q ，也可写成 log-weight z ($q = \text{softmax}(z)$) 或平方根概率 $h = \sqrt{q}$ 。三种表示描述同一个统计对象，却给出不同的普通欧氏长度。如果仅把某个坐标中的梯度归一化、走固定欧氏步并在两个位置直接拼接，那么更换坐标尺度就会改变第一方向、第二个 probe 点和最终近邻；此时“相似”是实现坐标的性质，而不是候选行为的性质。

由筛选目的可得到三个设计要求：

1. **方向不变：**同一损失微分在不同光滑坐标中应对应同一个分布切向量；
2. **探测尺度不变：**所有候选的第二点应距起点相同的统计距离，而不是相同的坐标增量；
3. **跨点比较不变：**起点和第二点的方向属于不同切空间，必须先用同一几何规则对齐，才能比较。

Fisher 度量、它的指数映射和 Levi-Civita 平行移动正好依次实现这三项要求。所以本文选择 Fisher 几何首先是为了让“行为近邻”成为良定义的统计量；它相对欧氏两点的实证增益是验证，而不是选择该几何的唯一理由。

1.3 一句话版本

在同一小批固定 rollout 上，观察完整程序对 C 在当前位置的 **Fisher 单位下降方向**以及沿该方向走相同信息弧长后的新方向；若这两个方向都与已有程序对接近，则降低为它安排真实训练的概率，但永远保留非零审计概率。

1.4 旧版哪些组件被删除

表 1 列出这次最小化的边界。第二组随机 probe bank 只用于离线复核结论，部署时不构成第二条描述符通道。

表 1: 最终保留项与已删除项。

保留	单模块变异；完整 $C = (f, g)$ 联合求值；一个 checkpoint rollout bank；两次损失求导；Fisher 单位化；一次固定弧长 $\ell = 0.03$ 的闭式指数映射；一次闭式平行移动；两个单位方向；软筛选与非零审计；真实 on-policy fitness。
删除	scratch/warm 双锚点；30/60 步积分和数值 ODE；第三个流点；对数映射与曲率残差；候选级自适应步长；ESS 截断或通道；稳健多通道融合；Gram 特征；随机投影；由描述符驱动的额外父代密度奖励。

2 预备知识：从表型等价到统计流形

本节只使用概率、偏导数、向量内积和单位球面。Fisher 几何在这里不是一套多步优化器，而是把“同一个下降方向”“同样远的 probe”和“不同点的方向比较”定义成与坐标表示无关的对象。

2.1 参考 rollout bank

固定一个参考策略检查点 θ_{ref} 。对 R 个问题实例分别采样 M 条轨迹，得到

$$\mathcal{D}^{(r)} = \{(\tau_m, o_m, p_m^0)\}_{m=1}^M, \quad r = 1, \dots, R,$$

其中 o_m 是任务目标值， $p_m^0 = \log \pi_{\theta_{\text{ref}}}(\tau_m)$ 是参考策略给该轨迹的 log-probability。当前实验使用 $R = 8$ 、 $M = 100$ 。这个 bank 在比较所有候选时固定，因此候选之间的距离不会被 rollout 噪声主导。

这里的“固定”只针对廉价筛选。真正获得 fitness 时，候选仍按标准 on-policy 流程训练并重新采样。

2.2 完整程序对诱导的损失

对某个实例的数据 $\mathcal{D}$ ，程序 g 先构造带权偏好对集合

$$\mathcal{P}_g(\mathcal{D}, q) = \{(i_k^+, i_k^-, w_k)\}_{k=1}^K,$$

其中 i_k^+ 、 i_k^- 是一对轨迹的下标， $w_k \geq 0$ 是该对权重。程序 f 再为每个偏好对输出损失

$$\ell_k = f(p_{i_k^+}, p_{i_k^-}, o_{i_k^+}, o_{i_k^-}, \text{Stat}_q(\mathcal{D})).$$

因此完整程序对 $C = (f, g)$ 的损失为

$$\mathcal{L}_C(q) = \frac{\sum_{k=1}^K w_k \ell_k}{\sum_{k=1}^K w_k + \delta}, \quad (1)$$

其中 $\delta > 0$ 只防止分母为零。 $q = (q_1, \dots, q_M)$ 是当前经验分布；凡是程序中出现的均值、方差、分位数或其他集合统计量，都必须用当前 q 重新计算。这一步保证描述符测量的是完整 f - g 组合，而不是分别给两个程序贴标签。

2.3 经验 log-weight 坐标

令 $z \in \mathbb{R}^M$ 为经验 log-weight，并定义

$$q = \text{softmax}(z), \quad q_m = \frac{e^{z_m}}{\sum_j e^{z_j}}.$$

起点取均匀经验分布 $q_m^0 = 1/M$ ，可令 $z_m^0 = \log q_m^0$ 。当 q 改变时，用

$$p_m(q) = p_m^0 + \log \frac{q_m}{q_m^0} \quad (2)$$

构造候选损失的局部压力测试。

式 (2) 不是在声称任意 q 都能由某个共享参数策略精确实现；它只是对已经采到的有限支持做一次可重复的重加权实验。因此本文不把虚拟路径称为网络参数训练轨迹，也不使用“策略流形上的真实测地线”这一强解释。

2.4 为什么不变度量必须是 Fisher–Rao

所有严格为正且和为 1 的 q 构成概率单纯形

$$\Delta_M^\circ = \{q \in \mathbb{R}^M : q_m > 0, \mathbf{1}^\top q = 1\}.$$

它在 q 处的切向量 v 必须满足 $\mathbf{1}^\top v = 0$ ，因为概率总和不能改变。先在单纯形上任取一个 $M-1$ 维局部坐标 ξ ，并用 G_ξ 表示度量矩阵。若另一组坐标 η 描述同一分布，令 $\xi = \phi(\eta)$ 、 $J = \partial\xi/\partial\eta$ 。损失梯度是余切向量，满足 $\nabla_\eta \mathcal{L} = J^\top \nabla_\xi \mathcal{L}$ 。要让一个下降方向表示同一个分布变化，度量必须按

$$G_\eta = J^\top G_\xi J$$

变换。于是自然梯度满足

$$G_\eta^{-1} \nabla_\eta \mathcal{L} = J^{-1} G_\xi^{-1} \nabla_\xi \mathcal{L}, \quad \|G_\eta^{-1} \nabla_\eta \mathcal{L}\|_{G_\eta} = \|G_\xi^{-1} \nabla_\xi \mathcal{L}\|_{G_\xi}. \quad (3)$$

等式左、右只是同一个切向量在两组坐标中的分量；其长度不变。

还需要决定在概率模型上选择哪一个度量。在对充分统计或 Markov 嵌入保持不变的要求下，经典信息几何中的度量在整体常数因子外由 Fisher 度量唯一确定 [1]。这正符合本文的语义：若对 rollout 做不丢失信息的重新编码，程序对的行为距离不应改变。在一般坐标 ξ 中，Fisher 信息矩阵写成

$$G_\xi(q) = \mathbb{E}_{m \sim q} \left[\nabla_\xi \log q_m \nabla_\xi \log q_m^\top \right].$$

固定整体常数为 1 后，它在单纯形概率坐标中的切空间形式为

$$\langle v, w \rangle_q = \sum_{m=1}^M \frac{v_m w_m}{q_m}, \quad \|v\|_q = \sqrt{\sum_{m=1}^M \frac{v_m^2}{q_m}}. \quad (4)$$

直觉上，改变一个当前概率很小的轨迹更显著，所以同样的 v_m 会被 $1/q_m$ 放大。

欧氏归一化为何不满足要求。考虑同一局部状态的二维坐标，并把第一坐标任意改写为 $\bar{\xi}_1 = a\xi_1$ 、 $\bar{\xi}_2 = \xi_2$ 。同一个切向量 $v = (v_1, v_2)$ 在新坐标中写成 $\bar{v} = (av_1, v_2)$ ，普通欧氏长度从 $\sqrt{v_1^2 + v_2^2}$ 变成 $\sqrt{a^2 v_1^2 + v_2^2}$ 。只要 $a \neq 1$ ，欧氏单位方向和固定步的终点一般都会改变。这个反例不涉及数据或候选差异，只来自坐标单位的选择。相反，式 (3) 中的 Fisher 长度会让度量矩阵同时变换，因而抵消这个任意缩放。

令 $h = \sqrt{q}$ (逐元开方)，则 $\|h\|_2 = 1$ ，概率单纯形被映到单位球面的正象限。式 (4) 的线元满足

$$ds_{\text{FR}}^2 = 4 dh^\top dh.$$

因此 Fisher–Rao 弧长等于球面弧长的两倍。这个平方根表示使后面的指数映射和平行移动都有闭式解，无需数值积分。

2.5 完整程序对的 Fisher 单位自然梯度

在当前 q 处，对有效 log-probability 求负梯度：

$$c_C(q) = -\nabla_p \mathcal{L}_C(q) \in \mathbb{R}^M.$$

求这一次局部导数时，把当前 q 已经确定的配对、权重和集合统计量视为常量；移动到 q_1 后再完整重算它们。这样得到的是程序在两个局部状态下的响应，而不是对离散配对规则强行求导。对所有 p_m 同时加同一个常数不会改变 softmax 分布。将这个余切向量用 Fisher 逆度量升为切向量，并去掉无意义的共同平移，得到负自然梯度

$$u_C(q) = c_C(q) - q \mathbf{1}^\top c_C(q), \quad \mathbf{1}^\top u_C(q) = 0. \quad (5)$$

这里“自然梯度”不是新的 score 的导数； u_C 就是原损失梯度在 Fisher 度量下对应的下降切向量。可直接验证，对任意 $\mathbf{1}^\top v = 0$ ，有

$$\langle u_C, v \rangle_q = -d\mathcal{L}_C(q)[v].$$

令 $s_C(q) = \|u_C(q)\|_q$ 。为了用普通向量计算保存 Fisher 单位方向，把它写到平方根球面坐标中：

$$d_C(q) = \frac{u_C(q)}{\sqrt{q} s_C(q)}, \quad s_C(q) > \delta. \quad (6)$$

其中除法和开方均逐元进行；若 $s_C(q) \leq \delta$ ，按后文失败保护处理，而不伪造单位方向。当 $s_C(q) > \delta$ 时， $\|d_C(q)\|_2 = 1$ ，且 $\langle d_C(q), \sqrt{q} \rangle_2 = 0$ ，所以它是球面切空间中的单位向量。 $d_C(q)$ 表示候选在这组轨迹上“想相对提高哪些轨迹、压低哪些轨迹”；Fisher 单位化同时消去整体梯度幅值并保持概率重参数化不变。

3 轻量 Fisher 不变两点响应

3.1 第一点：候选的初始方向

对第 r 个实例，从均匀分布 $q_0^{(r)}$ 出发，令 $h_0^{(r)} = \sqrt{q_0^{(r)}}$ ，按式 (1)–(6) 计算

$$d_0^{(r)} = d_C(q_0^{(r)}).$$

这个方向已经包含完整程序对的主要行为信息。实验也显示，公平地逐实例 Fisher 单位化后， d_0 与真实训练差异的全局相关性很高。但只看一个点仍可能把少量训练结果差异很大的候选放得过近，因此它不能单独承担跳过训练的决定。

3.2 固定弧长的一次闭式指数映射

沿候选自己的初始方向走固定 Fisher–Rao 弧长 $\ell = 0.03$ 。由于平方根球面的弧长是 Fisher–Rao 弧长的一半，这一步的闭式解为

$$h_1^{(r)} = \cos\left(\frac{\ell}{2}\right) h_0^{(r)} + \sin\left(\frac{\ell}{2}\right) d_0^{(r)}, \quad q_1^{(r)} = h_1^{(r)} \odot h_1^{(r)}, \quad \ell = 0.03, \quad (7)$$

其中 $\odot$ 表示逐元乘法。这是沿 Fisher 单位自然梯度的一次精确测地步，不需要 ODE 积分，也不为不同候选调节长度。

然后在 $q_1^{(r)}$ 下完整重算式 (2) 中的 $p(q_1)$ 、所有依赖 q_1 的集合统计量、程序 g 的配对与权重，以及完整损失的 Fisher 单位方向：

$$\tilde{d}_1^{(r)} = d_C(q_1^{(r)}).$$

第二点不是由外部随意选择的 probe，而是由候选的 d_0 自己产生。所以 $\tilde{d}_1$ 回答的是：当经验分布沿该候选最想推动的方向走同样小的信息距离后，它还会怎样推动？

3.3 把第二方向移回共同切空间

$d_0^{(r)}$ 位于 $h_0^{(r)}$ 的切空间， $\tilde{d}_1^{(r)}$ 位于 $h_1^{(r)}$ 的切空间；不先对齐就直接减或拼接，会依赖所选坐标。沿式 (7) 的球面短测地线，把 $\tilde{d}_1^{(r)}$ 平行移动回 $h_0^{(r)}$ ：

$$d_1^{(r)} = \tilde{d}_1^{(r)} - \frac{\langle \tilde{d}_1^{(r)}, h_0^{(r)} \rangle_2}{1 + \langle h_1^{(r)}, h_0^{(r)} \rangle_2} (h_1^{(r)} + h_0^{(r)}). \quad (8)$$

这个闭式操作保持向量长度和测地线上的夹角，并使 $d_0^{(r)}$ 与 $d_1^{(r)}$ 都在共同的 $h_0^{(r)}$ 切空间中。

3.4 统一描述符与距离

把 R 个实例的两个对齐方向直接拼接并归一化：

$$\Psi(C) = \frac{1}{\sqrt{2R}} \text{concat}_{r=1}^R [d_0^{(r)} \parallel d_1^{(r)}]. \quad (9)$$

两个候选的行为距离为共同切坐标中的欧氏距离

$$D(C_a, C_b) = \|\Psi(C_a) - \Psi(C_b)\|_2. \quad (10)$$

因为每个 $d_t^{(r)}$ 都是 Fisher 单位方向的球面表示，式 (10) 汇总的是两个位置上的不变方向夹角差异。这里的“轻量 Fisher”只有 $O(M)$ 的逐元运算和内积；最终方法没有 Hessian、Jacobian–vector product、显式曲率或多步流积分。

为什么式 (10) 最后仍写成欧氏范数？这里的欧氏范数只是在完成 Fisher 单位化、测地移动和平行对齐后的共同正交坐标中计算内积，并没有把概率单纯形重新当作平直空间。平方根映射满足 $ds_{\text{FR}}^2 = 4 dh^\top dh$ ，所以球面切向量的普通内积正是 Fisher 内积的等距表示（相差已经固定的整体常数）。换言之，式 (10) 是不变几何的计算形式；欧氏基线则在得到不变方向、等信息终点和跨点对齐之前就使用坐标欧氏结构，两者不能由最终都出现 ℓ_2 范数而等同。

为什么不是只保存方向差 $d_1 - d_0$ ？只保存差会丢失两个候选在起点朝向完全不同这一重要信息。拼接 $[d_0 \parallel d_1]$ 同时保留全局的一阶行为和局部的方向响应；实验中它比原始两点梯度差更可靠。

为什么一步就够？三点曲率与只用前两点的早期曲率在六个设置中几乎相同；把 30 步积分压到 3 次粗粒度求导也不改变结论；进一步比较后，一次固定弧长扰动得到的两个单位方向已经保留有效近邻关系。继续积分主要增加数值与实现复杂度，没有观察到独立收益。

3.5 描述符计算过程

对单个候选 C ，计算过程如下。

1. 读取固定参考 bank 的第 r 个实例，设 $q_0 = \mathbf{1}/M$ 、 $h_0 = \sqrt{q_0}$ 。
2. 用完整 $C = (f, g)$ 计算 $\mathcal{L}_C(q_0)$ ，求 c_0 、 u_0 ，Fisher 单位化得到 d_0 。
3. 按式 (7) 沿 d_0 走固定弧长 $\ell = 0.03$ ，得到 q_1 。
4. 在 q_1 下重新计算有效 log-probability、统计量、配对、权重和完整损失，得到 $\tilde{d}_1$ 。
5. 按式 (8) 把 $\tilde{d}_1$ 平行移动回 h_0 得到 d_1 ；对所有 R 个实例重复，并按式 (9) 拼接。

这两次求导只针对候选表达式在有限 rollout 上的输出，不修改网络参数，也不需要重要性采样生成新的轨迹。指数映射与平行移动都是闭式 $O(M)$ 操作，不增加候选损失求导次数。

4 用描述符分配真实训练预算

4.1 代表集与最近邻

维护已完成真实训练的代表集

$$\mathcal{A} = \{(C_i, \Psi(C_i), F_i)\}_{i=1}^N,$$

其中 F_i 是真实 on-policy 训练得到的 fitness。新候选 C 到代表集的距离为

$$D_{\min}(C) = \min_{C_i \in \mathcal{A}} D(C, C_i).$$

描述符只回答“它是否像已训练过的候选”，不回答“它的性能有多高”。

4.2 软筛选而非硬删除

真实训练概率定义为

$$P_{\text{train}}(C) = \varepsilon_{\text{audit}} + (1 - \varepsilon_{\text{audit}}) \text{sigmoid}\left(\frac{D_{\min}(C) - \tau}{T}\right), \quad (11)$$

其中 τ 是距离中心, $T > 0$ 控制过渡平滑程度, $\varepsilon_{\text{audit}} > 0$ 是审计下限。距离很远的候选几乎一定训练; 距离很近的候选大多被延后, 但仍以至少 $\varepsilon_{\text{audit}}$ 的概率训练。

没有训练的候选不会复制最近邻的 fitness, 也不会被永久宣布为等价; 它只是在当前预算轮次中被合并记录或延后。审计样本用于在线估计近邻误跳过率, 并据此调节 τ 、 T 或暂时关闭筛选。

4.3 搜索循环

完整搜索只保留以下步骤:

1. 按真实 fitness 从已训练种群中选择父代; 描述符不再额外提供密度奖励。
2. 随机选择只变异 f 或只变异 g , 另一个程序保持不变。
3. 对新组合的完整 $C = (f, g)$ 计算 $\Psi(C)$ 与 $D_{\min}(C)$ 。
4. 按式 (11) 决定是否分配真实训练预算。
5. 若训练, 则执行标准 on-policy 训练并记录 $F(C)$, 再把它加入代表集; 否则只记录审计信息。

因此 RFPS 是预算筛选器加因子化搜索协议, 而不是用离线描述符代替 fitness 的代理模型。

5 与已有方法及廉价基线的区别

5.1 相关工作的边界

本文把相关工作限定为“使用相同数学工具解决相似机器学习问题”。因此只保留两条近邻: 一条是用局部梯度判断损失程序是否重复的损失搜索; 另一条是用 Fisher 度量规范概率分布局部更新的策略优化。一般神经架构搜索、代理模型或泛化多样性搜索不在这个边界内。

第一条中, 最直接的参照是 AutoLoss-Zero 的 gradient-equivalence check: 它在若干预测样本上比较候选损失产生的梯度范数, 并对等价候选复用评价结果 [2]。第二条中, Fisher 度量的不变性与唯一性给出了概率单纯形上不依赖坐标的局部长度 [1]; TRPO 等方法用这类信息距离约束真实策略参数更新 [3]。RFPS 不是策略优化器: 它只在固定 rollout 的经验分布上取一次固定弧长 probe, 用来筛选损失程序对。

因此这里的差异不是“把同一个梯度范数多算一次”, 而是把完整程序对的自诱导两点方向响应作为表型。

5.2 与更直接的梯度基线比较

为了避免几何包装掩盖简单答案, 我们正面对比以下描述符:

- 初始未归一化梯度: 只看一个点, 保留幅值;

表 2: RFPS 与 AutoLoss-Zero 梯度等价检查的实质区别。

	AutoLoss-Zero	本文 RFPS
搜索单位	单个损失程序	完整偏好程序对 $C = (f, g)$
局部观测	若干点上的梯度范数，主要是标量幅值	每个 rollout 上的完整 Fisher 单位方向
观测位置	固定的单个局部状态	起点与候选自己沿固定信息弧长诱导的第二点
保留信息	候选把梯度推得多大	候选推向哪里，以及沿该方向走同样信息距离后还推向哪里
筛选动作	等价候选复用已有结果	只软分配训练预算，保留非零审计率，不伪造 fitness

- 初始单位方向：每个 probe 分别归一化后的 d_0 ；
- 原始两点梯度差：保留幅值的 $c(q_1) - c(q_0)$ ；
- 有限差分 JVP/HVP 型特征：用两点梯度差近似局部场变化；
- 欧氏 log-weight 两点方向对：在同一 bank 上令 $z_1 = z_0 + \ell u_0 / \|u_0\|_2$ ，并直接拼接两个坐标单位方向；它与最终方法共享两次求导和第一个方向，但没有等信息弧长与跨切空间对齐，用于检验不变几何的独立价值；
- 初始 Gram 特征：汇总不同 probe 方向之间的内积；
- 随机投影梯度轨迹：检验高维坐标是否只是冗余；
- 只用 f 或只用 g ：检验拆开评价是否丢失组合交互。

当前离线候选集能完整检验前七项；最后一项仍需要含有充分 g 变异的联合搜索数据。

5.3 创新性边界

本文可以支持的创新点有三条：

1. **因子化基因型、联合表型**：每次只让大模型变异一个短程序，但所有筛选方向都由完整 $C = (f, g)$ 产生。
2. **Fisher 不变的自诱导两点响应**：从“候选表型应属于概率分布而非任意坐标”这一要求出发，用 Fisher 自然梯度定义第一方向，用固定信息弧长产生候选自诱导的第二点，再经平行移动比较两个方向。描述符不把它们压成梯度范数或单个曲率标量。
3. **风险受控的预算用途**：方向距离只决定真实训练概率，不冒充性能预测；软筛选和审计下限允许在线发现固定支持造成的错误近邻。

本文不声称提出新的黎曼优化器或新的 Fisher 度量，不声称虚拟重加权等价于参数训练，也不声称高方向变化本身意味着高 fitness。新意在于先把程序对的表型等价定义成概率分布上的坐标不变局部响应等价，再把标准 Fisher 几何压缩成完整损失程序对的两点行为签名，并且只用于真实训练前的风险受控预筛。

表 3: 旧三点曲率、公平的一点单位方向、欧氏两点与最终 Fisher 两点。 ρ 越高越好, NN 与 FS 越低越好; FS 是在随机历史顺序下模拟 20% 跳过、并以 fitness 差超过 .01 为错误的平均误跳过率。

候选集/标签	seed	旧曲率 ρ	一点 d_0			欧氏两点			Fisher 两点		
			ρ	NN	FS	ρ	NN	FS	ρ	NN	FS
matched / scratch	1	.565	.803	.00659	.142	.806	.00659	.112	.808	.00659	.112
matched / scratch	2	.578	.806	.00659	.142	.810	.00659	.030	.816	.00659	.030
matched / warm	1	.552	.851	.00122	.125	.853	.00122	.000	.856	.00113	.000
matched / warm	2	.573	.853	.00133	.125	.855	.00133	.000	.863	.00113	.000
external / scratch	1	.454	.713	.00731	.106	.712	.00662	.109	.714	.00689	.109
external / scratch	2	.487	.715	.00731	.106	.715	.00689	.109	.716	.00689	.109

6 最小化消融证据

6.1 设置与指标

消融在方案锁定后运行。数据包括: (1) 40 个同时具有 from-scratch 与 checkpoint-135 warm-start 高保真标签的匹配候选; (2) 65 个未参与旧曲率公式选择的外部 scratch 候选。每个描述符使用 8 个 TSP100 实例、每实例 100 个 POMO starts, 并用两组独立随机 bank 复核。旧版 Fisher 流使用共同弧长 0.10、30 个积分步和三个检查点; 最终方法只使用一个 warm checkpoint bank、式 (7) 的一次闭式 Fisher 步和式 (8) 的一次闭式平行移动。

对所有候选对, 令 d_{ij} 为描述符距离, $y_{ij} = |F_i - F_j|$ 为真实 fitness 差。评价包括:

- ρ : d_{ij} 与 y_{ij} 的 Spearman 相关, 越高越好;
- NN: 每个候选的描述符最近邻对应的真实 fitness 误差中位数, 越低越好;
- 误跳过率: 按随机历史顺序模拟固定 20% 跳过率, 把 fitness 差超过 0.01 的近邻跳过计为错误。

这些指标测量筛选描述符, 不等价于完整搜索的最终 best-so-far; 完整搜索仍需报告相同真实训练预算下找到的最好程序对。

6.2 主结果

表 3 给出两个 probe seed 的结果。旧曲率列对 scratch 标签使用其匹配 scratch bank, 对 warm 标签使用匹配 warm bank; 公平一阶基线、欧氏两点和最终 Fisher 两点描述符都只使用同一个 warm checkpoint bank。因此最终方法不仅计算更少, 还取消了双锚点。

结果说明三件事。第一, 逐 probe 单位化的一点方向比旧曲率拥有更高的全局相关性; 旧文中“二阶估计优于一阶估计”的结论只对未做公平单位化的一阶欧氏距离成立, 不能写成一般结论。第二, 一点方向仍会产生危险的尾部碰撞: 在两组 matched scratch 模拟中, 其平均误跳过率均为 .142, 被误跳过候选的平均 fitness 误差约为 .063; matched warm 的一点误跳过率为 .125。加入第二点方向后, matched scratch 的误跳过率降为 .112/.030, matched warm 降为 .000/.000; 同时既保留一点方向的高 ρ , 又把被误跳过候选的平均误差降到约 0.001–0.006。这才是保留第二次求导的理由。第三, 在相同两次求导预算下, Fisher 版在六个设置中相对欧氏版的 ρ 分别提高

.002, .006, .003, .008, .002, .001, 且误跳过率没有增加。这里不把小幅数值差解释成“Fisher 预测能力远强于欧氏空间”；更准确的结论是：两点观测贡献主要预测增益，而 Fisher 以相同求导次数把这个有效经验构造提升为坐标不变的描述符，并在所有设置中没有为不变性付出精度代价。

欧氏两点看起来接近并不意味着两种定义等价。当前实验从均匀 q_0 出发，此时 Fisher 权重在第一点只是共同常数，所以两种方法共享几乎相同的 d_0 ；同时 $\ell = .03$ 很短，第二方向仍靠近第一方向，描述符的主要信号自然相似。欧氏基线因此是 Fisher 描述符在一个固定坐标、一个近均匀起点和一个短程区域内的局部近似。一旦更换概率坐标、起点远离均匀分布，或比较不同点的方向，它便不再保证给出相同近邻；Fisher 构造则由式 (3) 保证描述的是同一个统计对象。鉴于闭式指数映射与平行移动只增加 $O(M)$ 逐元运算而不增加求导次数，最终方法保留轻量 Fisher，但不恢复多步流或曲率系统。

6.3 每个旧组件是否有独立贡献

表 4: 组件级结论。删除决定以同一候选、同一真实标签上的对照为依据。

对照	观察	决定
第三个流点	只用前两个点的早期曲率与完整三点曲率在六个设置中的 ρ 最大差约 .002，最近邻误差无实质恶化。	删除
30 步积分	3 次粗粒度重求导复现曲率；一次扰动后的方向对进一步复现有效近邻。	删除
原始两点梯度差	六个设置的 ρ 仅约 .10–.28；梯度幅值遮蔽了方向变化。	拒绝
公平一点单位方向	ρ 达 .627–.853，但在相似度尾部出现高 fitness 差碰撞。	只作第一半
Fisher 与欧氏两点	欧氏基线在当前均匀起点和短步长下是强局部近似；Fisher 版在六个设置中 ρ 一致持平或小幅提高，且不增加求导次数或误跳过率，同时使方向、探测长度与跨点比较不依赖坐标。	保留轻量 Fisher
候选级自适应弧长	固定 forward/reverse KL 或 ESS 改变解回的 Fisher 弧长 CV 不超过 .002，与固定 .03 的描述符指标相同；max-log 和 turning 自适应也无稳定收益。	删除自适应
scratch/warm 双锚点	单个 warm checkpoint bank 同时预测 scratch 与 warm 标签，且 scratch ρ 约 .80、外部 ρ 约 .71。	删除双锚点
初始 Gram	与逐 probe 单位方向的距离相关约 .98–.995，且继承相同危险碰撞。	删除
随机投影	可近似保留旧曲率，但只是在压缩冗余高维坐标，没有新增机制。	删除

6.4 弧长与探针选择

$\ell \in \{0.01, 0.03, 0.10\}$ 时，Fisher 两点方向对的 ρ 基本稳定。0.01 在匹配集合上偶尔使第二点离第一点太近，方向分辨率不足；0.10 没有稳定增益，且在一个 scratch 设置中使误跳过率轻微恶化。因此当前固定 $\ell = 0.03$ ，不把弧长作为候选级超参数。

这里要区分“度量不变”与“步长自动唯一”。Fisher 度量在整体常数外由不变性确定，但它不

会单独决定应走多远。我们固定度量的尺度为 1，再固定一个对所有候选相同的短弧 0.03。这使候选间比较公平，也避免为了选步长又引入一组与候选相关的新规则。额外实验中，用相同的 forward KL、reverse KL 或 ESS 改变反解弧长时，各候选得到的弧长几乎都是 0.03；而用最大 log-ratio 或方向转角调节弧长没有稳定提高筛选指标。因此固定短弧是实验与简洁性共同支持的最小选择。

两组独立 bank 的结论相近，说明描述符不是依赖单次 rollout 噪声的偶然现象。部署时只保留一组由 checkpoint-135 生成的 $R = 8$ 个实例；第二组仅作为实验复核，不需要融合尺度或投票。

7 搜索空间覆盖与程序合法性

方法能否找到有效目标，取决于 f 与 g 的 DSL 是否覆盖已知偏好结构，而不取决于描述符公式本身。最低覆盖要求是：

- f 能表达 log-sigmoid、差值、缩放、截断与基本集合归一化，例如

$$f_{\text{pair}}(\Delta p) = -\log \text{sigmoid}(\beta \Delta p);$$

- g 能表达全体有序对、最好样本锚定、top- K /rank 选择，以及依赖目标值差或目标值比的非负权重；
- f 和 g 的所有保护算子在两次 probe 上都必须返回有限标量、有限梯度与非空有效偏好对。

这使程序对能够覆盖常见的成对偏好目标，以及“最佳轨迹作锚点、目标尺度控制权重”的组合优化偏好目标。搜索前应运行可执行资格测试，而不是只靠语法检查：随机生成合法输入，检查输出有限性、梯度非零率、交换正负样本时的响应，以及极端目标尺度下是否触发保护边界。

8 计算代价

设每个实例有 M 条轨迹，程序 g 产生 K 个偏好对，候选表达式一次前后向代价记为 $B(M, K)$ 。最终描述符对每个实例恰好计算两次候选损失，加上线性代价的几何操作，总代价为

$$O(2RB(M, K) + RM).$$

其中 Fisher 单位化、指数映射和平行移动都只含逐元运算与向量内积。它不进行网络的前向或反向传播，不更新参数，不重新 rollout，也不存储 $M \times M$ Fisher 矩阵或 Hessian。

旧版若以 H 个积分步重算候选场，代价约为 $O(RHB)$ ，另有多个对数映射、多次平行移动和多锚点开销。在当前 $H = 30$ 且双锚点的实现中，删减后的候选求导次数从量级 $60R$ 降为 $2R$ ；这是结构性降本，而不只是常数优化。

9 实现边界与失败保护

1. **固定支持：**描述符只能观察参考 bank 已覆盖的轨迹；它无法发现候选在全新状态上的差异。解决方式是保留审计率，并周期性更新整个 bank，而不是为每个候选单独 rollout。

2. **虚拟分布可实现性**：式 (2) 不保证存在网络参数精确实现 q_1 。因此它是局部压力测试，不是参数训练的无偏估计，也无需声称使用重要性采样即可替代训练。
3. **经验流形的边界**：Fisher 度量的唯一性适用于本文选定的有限支持概率单纯形，它不把 q 自动变成共享参数策略的完整流形。
4. **固定弧长的含义**：不变度量确定了如何测量，但不唯一确定 ℓ 。0.03 是对所有候选公用并经消融选定的短弧，不声称等于某个真实优化器的参数步。
5. **数值边界**：若 $s_C(q)$ 太小、任一 q_m 接近数值下溢、配对为空或产生非有限值，候选不能因“距离近”而被跳过；应直接送入审计或判为非法程序。
6. **描述符不是价值**：大距离只表示行为新，不表示性能好；父代选择与最终排名只使用真实 fitness。
7. **g 变化的证据仍不足**：当前最小化消融主要来自固定参考 g 、变化 f 的历史候选。联合搜索上线前必须单独报告只变 f 、只变 g 、两者都变三组的近邻可靠性。
8. **最终搜索证据**：离线相关和误跳过率只能证明筛选器有信号；论文主实验仍应比较相同真实训练预算下的 best-so-far、有效候选数与审计漏失。

10 符号表

符号	含义
$C = (f, g)$	完整程序对； f 生成逐对损失， g 生成偏好对与权重
R, M, K	probe 实例数、每实例轨迹数、程序 g 生成的偏好对数
p_m^0, o_m	第 m 条参考轨迹的 log-probability 与任务目标值
z, q, h	经验 log-weight、其 softmax 概率与平方根坐标 $h = \sqrt{q}$
$\mathcal{L}_C(q)$	在当前经验分布下由完整程序对产生的加权损失
c, u, d	负 log-probability 梯度、Fisher 负自然梯度、其平方根球面单位方向
ℓ	一次自诱导 Fisher-Rao 弧长，对所有候选固定为 0.03
$\Psi(C)$	所有实例的 $[d_0 \parallel d_1]$ 拼接描述符
$D(C_a, C_b)$	两个程序对的描述符欧氏距离
$F(C)$	真实 on-policy 训练得到的 fitness
τ, T	软筛选的距离中心与温度
$\varepsilon_{\text{audit}}$	即使极近也保留的最小真实训练概率

11 结论

最小化后的 RFPS 不再依赖“黎曼曲率”叙事。它从一个更基本的定义出发：程序对的廉价表型应描述经验分布上的训练压力，并且不应随概率、log-weight 或平方根概率等坐标表示改变。完整程序对在固定 rollout 上的 **Fisher 单位自然梯度** 提供坐标不变的主要行为信号；沿该方向走固

定信息短弧后、再平行移回的**第二个单位方向**能减少危险的局部碰撞。因此最终方法只需要一个参考 bank、两次候选损失求导、一次闭式指数映射和一次闭式平行移动。

这个版本的核心贡献不是发明新几何，也不是宣称欧氏两点在当前数据上失效，而是把“坐标不变的局部响应等价”确立为程序对筛选原则，并把标准 Fisher 几何压缩成一个两点、固定弧长、无积分的行为签名。由此，两个相互作用的短程序被放进同一个有统计语义、可审计的行为表型中，用于谨慎分配昂贵的真实训练预算。

参考文献

- [1] Hông Vân Lê. The uniqueness of the fisher metric as information metric. *arXiv preprint arXiv:1306.1465*, 2013.
- [2] Hao Li, Tianwen Fu, Jifeng Dai, Hongsheng Li, Gao Huang, and Xizhou Zhu. Autoloss-zero: Searching loss functions from scratch for generic tasks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1009–1018, June 2022.
- [3] John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In Francis Bach and David Blei, editors, *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *Proceedings of Machine Learning Research*, pages 1889–1897. PMLR, 2015.