

RFPS 方法说明

用轻量 Fisher 不变两点响应筛选因子化偏好程序对

方法版本 5.0（固定弧长修订）

2026 年 7 月 28 日

摘要

本文给出 RFPS (*Response-Field Program-pair Search*, 响应场程序对搜索) 的最小版本。搜索变量仍是两个短程序 $C = (f, g)$: g 决定如何构造和加权偏好对, f 决定每个偏好对产生什么损失; 变异时每次只改一个程序, 但筛选和训练始终评价完整组合。为了在真实训练前发现行为近似重复的组合, 我们在一个固定参考检查点生成的 rollout bank 上, 把经验分布看作概率单纯形。候选损失先产生 Fisher 单位自然梯度 d_0 ; 随后沿 d_0 做一次固定 Fisher-Rao 弧长 $\ell = 0.03$ 的闭式指数映射, 在新点重新计算方向, 并把它闭式平行移动回起点得到 d_1 。把 (d_0, d_1) 拼接, 便得到唯一的行为描述符。

这次修订只保留 Fisher 几何中保证坐标不变性所必需的三个操作: 单位化、一次指数映射和一次平行移动; 双锚点、30/60 步积分、第三个流点、曲率残差、自适应步长、ESS 通道、Gram 通道、随机投影和额外的多样性父代模块全部删除。两组独立 probe 的离线消融表明: 该描述符只需两次候选损失求导; 相较欧氏两点响应, 它在 scratch、warm-start 和外部候选集上的相关性一致持平或小幅提高, 且没有增加危险近邻的误跳过率。描述符只用于软分配训练预算; 候选的 fitness 仍只来自真实 on-policy 训练。

目录

1 问题与最终方法	2
1.1 为什么仍然搜索两个程序	2
1.2 一句话版本	3
1.3 旧版哪些组件被删除	3
2 预备知识: 从固定 rollout 到局部方向	3
2.1 参考 rollout bank	3
2.2 完整程序对诱导的损失	4
2.3 经验 log-weight 坐标	4
2.4 Fisher-Rao 不变度量	4
2.5 完整程序对的 Fisher 单位自然梯度	5
3 轻量 Fisher 不变两点响应	5
3.1 第一点: 候选的初始方向	5

1 问题与最终方法	2
3.2 固定弧长的一次闭式指数映射	6
3.3 把第二方向移回共同切空间	6
3.4 统一描述符与距离	6
3.5 描述符计算过程	7
4 用描述符分配真实训练预算	7
4.1 代表集与最近邻	7
4.2 软筛选而非硬删除	7
4.3 搜索循环	8
5 与已有方法及廉价基线的区别	8
5.1 相关工作的边界	8
5.2 与更直接的梯度基线比较	8
5.3 创新性边界	9
6 最小化消融证据	9
6.1 设置与指标	9
6.2 主结果	10
6.3 每个旧组件是否有独立贡献	11
6.4 弧长与探针选择	11
7 搜索空间覆盖与程序合法性	12
8 计算代价	12
9 实现边界与失败保护	12
10 符号表	13
11 结论	13

1 问题与最终方法

1.1 为什么仍然搜索两个程序

一个偏好训练目标通常同时包含两个决定：

- **比较什么：**如何从 rollout 中选出偏好对、如何确定正负样本、如何加权；记为程序 g ；
- **怎样惩罚：**给定一对轨迹后，如何把 log-probability、目标值和集合统计量组合成标量损失；记为程序 f 。




图 1: 最终 RFPS 只有一条计算链。虚拟扰动不更新网络参数，也不生成新的 rollout。

因此候选基因型写成 $C = (f, g)$ 。每次只变异 f 或 g ，可以让大模型只生成一个短程序；但候选行为不是 f 与 g 的两个分数之和，而是二者组合后诱导的完整损失。RFPS 因而采用“因子化生成、联合表型评价”：生成问题被拆小，交互作用不被拆掉。

1.2 一句话版本

在同一小批固定 rollout 上，观察完整程序对 C 在当前位置的下降方向以及沿该方向走一小步后的新方向；若这两个方向都与已有程序对接近，则降低为它安排真实训练的概率，但永远保留非零审计概率。

1.3 旧版哪些组件被删除

表 1 列出这次最小化的边界。第二组随机 probe bank 只用于离线复核结论，部署时不构成第二条描述符通道。

表 1: 最终保留项与已删除项。

保留	单模块变异；完整 $C = (f, g)$ 联合求值；一个 checkpoint rollout bank；两次损失求导；Fisher 单位化；一次固定弧长 $\ell = 0.03$ 的闭式指数映射；一次闭式平行移动；两个单位方向；软筛选与非零审计；真实 on-policy fitness。
删除	scratch/warm 双锚点；30/60 步积分和数值 ODE；第三个流点；对数映射与曲率残差；候选级自适应步长；ESS 截断或通道；稳健多通道融合；Gram 特征；随机投影；由描述符驱动的额外父代密度奖励。

2 预备知识：从固定 rollout 到局部方向

本节只使用概率、偏导数、向量内积和单位球面。Fisher 几何在这里不是一套多步优化器，只是规定“方向多长”与“不同点的方向怎么比”。

2.1 参考 rollout bank

固定一个参考策略检查点 θ_{ref} 。对 R 个问题实例分别采样 M 条轨迹，得到

$$\mathcal{D}^{(r)} = \{(\tau_m, o_m, p_m^0)\}_{m=1}^M, \quad r = 1, \dots, R,$$

其中 o_m 是任务目标值, $p_m^0 = \log \pi_{\theta_{\text{ref}}}(\tau_m)$ 是参考策略给该轨迹的 log-probability。当前实验使用 $R = 8$ 、 $M = 100$ 。这个 bank 在比较所有候选时固定, 因此候选之间的距离不会被 rollout 噪声主导。

这里的“固定”只针对廉价筛选。真正获得 fitness 时, 候选仍按标准 on-policy 流程训练并重新采样。

2.2 完整程序对诱导的损失

对某个实例的数据 $\mathcal{D}$, 程序 g 先构造带权偏好对集合

$$\mathcal{P}_g(\mathcal{D}, q) = \{(i_k^+, i_k^-, w_k)\}_{k=1}^K,$$

其中 i_k^+ 、 i_k^- 是一对轨迹的下标, $w_k \geq 0$ 是该对权重。程序 f 再为每个偏好对输出损失

$$\ell_k = f(p_{i_k^+}, p_{i_k^-}, o_{i_k^+}, o_{i_k^-}, \text{Stat}_q(\mathcal{D})).$$

因此完整程序对 $C = (f, g)$ 的损失为

$$\mathcal{L}_C(q) = \frac{\sum_{k=1}^K w_k \ell_k}{\sum_{k=1}^K w_k + \delta}, \quad (1)$$

其中 $\delta > 0$ 只防止分母为零。 $q = (q_1, \dots, q_M)$ 是当前经验分布; 凡是程序中出现的均值、方差、分位数或其他集合统计量, 都必须用当前 q 重新计算。这一步保证描述符测量的是完整 f - g 组合, 而不是分别给两个程序贴标签。

2.3 经验 log-weight 坐标

令 $z \in \mathbb{R}^M$ 为经验 log-weight, 并定义

$$q = \text{softmax}(z), \quad q_m = \frac{e^{z_m}}{\sum_j e^{z_j}}.$$

起点取均匀经验分布 $q_m^0 = 1/M$, 可令 $z_m^0 = \log q_m^0$ 。当 q 改变时, 用

$$p_m(q) = p_m^0 + \log \frac{q_m}{q_m^0} \quad (2)$$

构造候选损失的局部压力测试。

式 (2) 不是在声称任意 q 都能由某个共享参数策略精确实现; 它只是对已经采到的有限支持做一次可重复的重加权实验。因此本文不把虚拟路径称为网络参数训练轨迹, 也不使用“策略流形上的真实测地线”这一强解释。

2.4 Fisher–Rao 不变度量

所有严格为正且和为 1 的 q 构成概率单纯形

$$\Delta_M^\circ = \{q \in \mathbb{R}^M : q_m > 0, \mathbf{1}^\top q = 1\}.$$

它在 q 处的切向量 v 必须满足 $\mathbf{1}^\top v = 0$ ，因为概率总和不能改变。在对充分统计或 Markov 嵌入保持不变的要求下，经典信息几何中的度量在整体常数因子外由 Fisher 度量唯一确定 [1]。固定这个常数为 1，定义

$$\langle v, w \rangle_q = \sum_{m=1}^M \frac{v_m w_m}{q_m}, \quad \|v\|_q = \sqrt{\sum_{m=1}^M \frac{v_m^2}{q_m}}. \quad (3)$$

直觉上，改变一个当前概率很小的轨迹更显著，所以同样的 v_m 会被 $1/q_m$ 放大。

令 $h = \sqrt{q}$ （逐元开方），则 $\|h\|_2 = 1$ ，概率单纯形被映到单位球面的正象限。式 (3) 的线元满足

$$ds_{\text{FR}}^2 = 4 dh^\top dh.$$

因此 Fisher–Rao 弧长等于球面弧长的两倍。这个平方根表示使后面的指数映射和平行移动都有闭式解，无需数值积分。

2.5 完整程序对的 Fisher 单位自然梯度

在当前 q 处，对有效 log-probability 求负梯度：

$$c_C(q) = -\nabla_p \mathcal{L}_C(q) \in \mathbb{R}^M.$$

求这一次局部导数时，把当前 q 已经确定的配对、权重和集合统计量视为常量；移动到 q_1 后再完整重算它们。这样得到的是程序在两个局部状态下的响应，而不是对离散配对规则强行求导。对所有 p_m 同时加同一个常数不会改变 softmax 分布。将这个余切向量用 Fisher 逆度量升为切向量，并去掉无意义的共同平移，得到负自然梯度

$$u_C(q) = c_C(q) - q \mathbf{1}^\top c_C(q), \quad \mathbf{1}^\top u_C(q) = 0. \quad (4)$$

这里“自然梯度”不是新的 score 的导数； u_C 就是原损失梯度在 Fisher 度量下对应的下降切向量。可直接验证，对任意 $\mathbf{1}^\top v = 0$ ，有

$$\langle u_C, v \rangle_q = -d\mathcal{L}_C(q)[v].$$

令 $s_C(q) = \|u_C(q)\|_q$ 。为了用普通向量计算保存 Fisher 单位方向，把它写到平方根球面坐标中：

$$d_C(q) = \frac{u_C(q)}{\sqrt{q} s_C(q)}, \quad s_C(q) > \delta. \quad (5)$$

其中除法和开方均逐元进行；若 $s_C(q) \leq \delta$ ，按后文失败保护处理，而不伪造单位方向。当 $s_C(q) > \delta$ 时， $\|d_C(q)\|_2 = 1$ ，且 $\langle d_C(q), \sqrt{q} \rangle_2 = 0$ ，所以它是球面切空间中的单位向量。 $d_C(q)$ 表示候选在这组轨迹上“想相对提高哪些轨迹、压低哪些轨迹”；Fisher 单位化同时消去整体梯度幅值并保持概率重参数化不变。

3 轻量 Fisher 不变两点响应

3.1 第一点：候选的初始方向

对第 r 个实例，从均匀分布 $q_0^{(r)}$ 出发，令 $h_0^{(r)} = \sqrt{q_0^{(r)}}$ ，按式 (1)–(5) 计算

$$d_0^{(r)} = d_C(q_0^{(r)}).$$

这个方向已经包含完整程序对的主要行为信息。实验也显示，公平地逐实例 Fisher 单位化后， d_0 与真实训练差异的全局相关性很高。但只看一个点仍可能把少量训练结果差异很大的候选放得过近，因此它不能单独承担跳过训练的决定。

3.2 固定弧长的一次闭式指数映射

沿候选自己的初始方向走固定 Fisher–Rao 弧长 $\ell = 0.03$ 。由于平方根球面的弧长是 Fisher–Rao 弧长的一半，这一步的闭式解为

$$h_1^{(r)} = \cos\left(\frac{\ell}{2}\right) h_0^{(r)} + \sin\left(\frac{\ell}{2}\right) d_0^{(r)}, \quad q_1^{(r)} = h_1^{(r)} \odot h_1^{(r)}, \quad \ell = 0.03, \quad (6)$$

其中 $\odot$ 表示逐元乘法。这是沿 Fisher 单位自然梯度的一次精确测地步，不需要 ODE 积分，也不为不同候选调节长度。

然后在 $q_1^{(r)}$ 下完整重算式 (2) 中的 $p(q_1)$ 、所有依赖 q_1 的集合统计量、程序 g 的配对与权重，以及完整损失的 Fisher 单位方向：

$$\tilde{d}_1^{(r)} = d_C(q_1^{(r)}).$$

第二点不是由外部随意选择的 probe，而是由候选的 d_0 自己产生。所以 $\tilde{d}_1$ 回答的是：当经验分布沿该候选最想推动的方向走同样小的信息距离后，它还会怎样推动？

3.3 把第二方向移回共同切空间

$d_0^{(r)}$ 位于 $h_0^{(r)}$ 的切空间， $\tilde{d}_1^{(r)}$ 位于 $h_1^{(r)}$ 的切空间；不先对齐就直接减或拼接，会依赖所选坐标。沿式 (6) 的球面短测地线，把 $\tilde{d}_1^{(r)}$ 平行移动回 $h_0^{(r)}$ ：

$$d_1^{(r)} = \tilde{d}_1^{(r)} - \frac{\langle \tilde{d}_1^{(r)}, h_0^{(r)} \rangle_2}{1 + \langle h_1^{(r)}, h_0^{(r)} \rangle_2} (h_1^{(r)} + h_0^{(r)}). \quad (7)$$

这个闭式操作保持向量长度和测地线上的夹角，并使 $d_0^{(r)}$ 与 $d_1^{(r)}$ 都在共同的 $h_0^{(r)}$ 切空间中。

3.4 统一描述符与距离

把 R 个实例的两个对齐方向直接拼接并归一化：

$$\Psi(C) = \frac{1}{\sqrt{2R}} \text{concat}_{r=1}^R [d_0^{(r)} \parallel d_1^{(r)}]. \quad (8)$$

两个候选的行为距离为共同切坐标中的欧氏距离

$$D(C_a, C_b) = \|\Psi(C_a) - \Psi(C_b)\|_2. \quad (9)$$

因为每个 $d_t^{(r)}$ 都是 Fisher 单位方向的球面表示，式 (9) 汇总的是两个位置上的不变方向夹角差异。这里的“轻量 Fisher”只有 $O(M)$ 的逐元运算和内积；最终方法没有 Hessian、Jacobian–vector product、显式曲率或多步流积分。

为什么不是只保存方向差 $d_1 - d_0$ ？只保存差会丢失两个候选在起点朝向完全不同这一重要信息。拼接 $[d_0 \parallel d_1]$ 同时保留全局的一阶行为和局部的方向响应；实验中它比原始两点梯度差更可靠。

为什么一步就够？ 三点曲率与只用前两点的早期曲率在六个设置中几乎相同；把 30 步积分压到 3 次粗粒度求导也不改变结论；进一步比较后，一次固定弧长扰动得到的两个单位方向已经保留有效近邻关系。继续积分主要增加数值与实现复杂度，没有观察到独立收益。

3.5 描述符计算过程

对单个候选 C ，计算过程如下。

1. 读取固定参考 bank 的第 r 个实例，设 $q_0 = \mathbf{1}/M$ 、 $h_0 = \sqrt{q_0}$ 。
2. 用完整 $C = (f, g)$ 计算 $\mathcal{L}_C(q_0)$ ，求 c_0 、 u_0 ，Fisher 单位化得到 d_0 。
3. 按式 (6) 沿 d_0 走固定弧长 $\ell = 0.03$ ，得到 q_1 。
4. 在 q_1 下重新计算有效 log-probability、统计量、配对、权重和完整损失，得到 $\tilde{d}_1$ 。
5. 按式 (7) 把 $\tilde{d}_1$ 平行移动回 h_0 得到 d_1 ；对所有 R 个实例重复，并按式 (8) 拼接。

这两次求导只针对候选表达式在有限 rollout 上的输出，不修改网络参数，也不需要重要性采样生成新的轨迹。指数映射与平行移动都是闭式 $O(M)$ 操作，不增加候选损失求导次数。

4 用描述符分配真实训练预算

4.1 代表集与最近邻

维护已完成真实训练的代表集

$$\mathcal{A} = \{(C_i, \Psi(C_i), F_i)\}_{i=1}^N,$$

其中 F_i 是真实 on-policy 训练得到的 fitness。新候选 C 到代表集的距离为

$$D_{\min}(C) = \min_{C_i \in \mathcal{A}} D(C, C_i).$$

描述符只回答“它是否像已训练过的候选”，不回答“它的性能有多高”。

4.2 软筛选而非硬删除

真实训练概率定义为

$$P_{\text{train}}(C) = \varepsilon_{\text{audit}} + (1 - \varepsilon_{\text{audit}}) \text{sigmoid}\left(\frac{D_{\min}(C) - \tau}{T}\right), \quad (10)$$

其中 τ 是距离中心， $T > 0$ 控制过渡平滑程度， $\varepsilon_{\text{audit}} > 0$ 是审计下限。距离很远的候选几乎一定训练；距离很近的候选大多被延后，但仍以至少 $\varepsilon_{\text{audit}}$ 的概率训练。

没有训练的候选不会复制最近邻的 fitness，也不会被永久宣布为等价；它只是在当前预算轮次中被合并记录或延后。审计样本用于在线估计近邻误跳过率，并据此调节 τ 、 T 或暂时关闭筛选。

4.3 搜索循环

完整搜索只保留以下步骤：

1. 按真实 fitness 从已训练种群中选择父代；描述符不再额外提供密度奖励。
2. 随机选择只变异 f 或只变异 g ，另一个程序保持不变。
3. 对新组合的完整 $C = (f, g)$ 计算 $\Psi(C)$ 与 $D_{\min}(C)$ 。
4. 按式 (10) 决定是否分配真实训练预算。
5. 若训练，则执行标准 on-policy 训练并记录 $F(C)$ ，再把它加入代表集；否则只记录审计信息。

因此 RFPS 是预算筛选器加因子化搜索协议，而不是用离线描述符代替 fitness 的代理模型。

5 与已有方法及廉价基线的区别

5.1 相关工作的边界

本文把相关工作限定为“使用相同数学工具解决相似机器学习问题”。因此只保留两条近邻：一条是用局部梯度判断损失程序是否重复的损失搜索；另一条是用 Fisher 度量规范概率分布局部更新的策略优化。一般神经架构搜索、代理模型或泛化多样性搜索不在这个边界内。

第一条中，最直接的参照是 AutoLoss-Zero 的 gradient-equivalence check：它在若干预测样本上比较候选损失产生的梯度范数，并对等价候选复用评价结果 [2]。第二条中，Fisher 度量的不变性与唯一性给出了概率单纯形上不依赖坐标的局部长度 [1]；TRPO 等方法用这类信息距离约束真实策略参数更新 [3]。RFPS 不是策略优化器：它只在固定 rollout 的经验分布上取一次固定弧长 probe，用来筛选损失程序对。

表 2: RFPS 与 AutoLoss-Zero 梯度等价检查的实质区别。

	AutoLoss-Zero	本文 RFPS
搜索单位	单个损失程序	完整偏好程序对 $C = (f, g)$
局部观测	若干点上的梯度范数，主要是标量幅值	每个 rollout 上的完整 Fisher 单位方向
观测位置	固定的单个局部状态	起点与候选自己沿固定信息弧长诱导的第二点
保留信息	候选把梯度推得多大	候选推向哪里，以及沿该方向走同样信息距离后还推向哪里
筛选动作	等价候选复用已有结果	只软分配训练预算，保留非零审计率，不伪造 fitness

因此这里的差异不是“把同一个梯度范数多算一次”，而是把完整程序对的自诱导两点方向响应作为表型。

5.2 与更直接的梯度基线比较

为了避免几何包装掩盖简单答案，我们正面对比以下描述符：

- 初始未归一化梯度：只看一个点，保留幅值；
- 初始单位方向：每个 probe 分别归一化后的 d_0 ；
- 原始两点梯度差：保留幅值的 $c(q_1) - c(q_0)$ ；
- 有限差分 JVP/HVP 型特征：用两点梯度差近似局部场变化；
- 欧氏两点方向对：在同一 bank 上去掉 Fisher 单位化、指数映射与平行移动，检验不变几何的独立价值；
- 初始 Gram 特征：汇总不同 probe 方向之间的内积；
- 随机投影梯度轨迹：检验高维坐标是否只是冗余；
- 只用 f 或只用 g ：检验拆开评价是否丢失组合交互。

当前离线候选集能完整检验前七项；最后一项仍需要含有充分 g 变异的联合搜索数据。

5.3 创新性边界

本文可以支持的创新点有三条：

1. **因子化基因型、联合表型**：每次只让大模型变异一个短程序，但所有筛选方向都由完整 $C = (f, g)$ 产生。
2. **Fisher 不变的自诱导两点响应**：第二个 probe 点不是手工指定，而是由候选自己的第一方向沿固定信息弧长产生；第二方向经平行移动后与第一方向在同一切空间比较。描述符不把它们压成梯度范数或单个曲率标量。
3. **风险受控的预算用途**：方向距离只决定真实训练概率，不冒充性能预测；软筛选和审计下限允许在线发现固定支持造成的错误近邻。

本文不声称提出新的黎曼优化器或新的 Fisher 度量，不声称虚拟重加权等价于参数训练，也不声称高方向变化本身意味着高 fitness。新意在于将这个轻量不变几何变成完整损失程序对的两点行为签名，并且只用于真实训练前的风险受控预筛。

6 最小化消融证据

6.1 设置与指标

消融在方案锁定后运行。数据包括：(1) 40 个同时具有 from-scratch 与 checkpoint-135 warm-start 高保真标签的匹配候选；(2) 65 个未参与旧曲率公式选择的外部 scratch 候选。每个描述符使用 8 个 TSP100 实例、每实例 100 个 POMO starts，并用两组独立随机 bank 复核。旧版 Fisher 流使用共同弧长 0.10、30 个积分步和三个检查点；最终方法只使用一个 warm checkpoint bank、式 (6) 的一次闭式 Fisher 步和式 (7) 的一次闭式平行移动。

对所有候选对，令 d_{ij} 为描述符距离， $y_{ij} = |F_i - F_j|$ 为真实 fitness 差。评价包括：

- ρ : d_{ij} 与 y_{ij} 的 Spearman 相关，越高越好；

表 3: 旧三点曲率、公平的一点单位方向、欧氏两点与最终 Fisher 两点。 ρ 越高越好, NN 与 FS 越低越好; FS 是在随机历史顺序下模拟 20% 跳过、并以 fitness 差超过 .01 为错误的平均误跳过率。

候选集/标签	seed	旧曲率 ρ	一点 d_0			欧氏两点			Fisher 两点		
			ρ	NN	FS	ρ	NN	FS	ρ	NN	FS
matched / scratch	1	.565	.803	.00659	.142	.806	.00659	.112	.808	.00659	.112
matched / scratch	2	.578	.806	.00659	.142	.810	.00659	.030	.816	.00659	.030
matched / warm	1	.552	.851	.00122	.125	.853	.00122	.000	.856	.00113	.000
matched / warm	2	.573	.853	.00133	.125	.855	.00133	.000	.863	.00113	.000
external / scratch	1	.454	.713	.00731	.106	.712	.00662	.109	.714	.00689	.109
external / scratch	2	.487	.715	.00731	.106	.715	.00689	.109	.716	.00689	.109

- NN: 每个候选的描述符最近邻对应的真实 fitness 误差中位数, 越低越好;
- 误跳过率: 按随机历史顺序模拟固定 20% 跳过率, 把 fitness 差超过 0.01 的近邻跳过计为错误。

这些指标测量筛选描述符, 不等价于完整搜索的最终 best-so-far; 完整搜索仍需报告相同真实训练预算下找到的最好程序对。

6.2 主结果

表 3 给出两个 probe seed 的结果。旧曲率列对 scratch 标签使用其匹配 scratch bank, 对 warm 标签使用匹配 warm bank; 公平一阶基线、欧氏两点和最终 Fisher 两点描述符都只使用同一个 warm checkpoint bank。因此最终方法不仅计算更少, 还取消了双锚点。

结果说明三件事。第一, 逐 probe 单位化的一点方向比旧曲率拥有更高的全局相关性; 旧文中“二阶估计优于一阶估计”的结论只对未做公平单位化的一阶欧氏距离成立, 不能写成一般结论。第二, 一点方向仍会产生危险的尾部碰撞: 在两组 matched scratch 模拟中, 其平均误跳过率均为 .142, 被误跳过候选的平均 fitness 误差约为 .063; matched warm 的一点误跳过率为 .125。加入第二点方向后, matched scratch 的误跳过率降为 .112/.030, matched warm 降为 .000/.000; 同时既保留一点方向的高 ρ , 又把被误跳过候选的平均误差降到约 0.001–0.006。这才是保留第二次求导的理由。第三, 在相同两次求导预算下, Fisher 版在六个设置中相对欧氏版的 ρ 分别提高 .002, .006, .003, .008, .002, .001, 且误跳过率没有增加。增益不大, 所以只保留闭式不变几何, 不恢复多步流或曲率系统。

6.3 每个旧组件是否有独立贡献

表 4: 组件级结论。删除决定以同一候选、同一真实标签上的对照为依据。

对照	观察	决定
第三个流点	只用前两个点的早期曲率与完整三点曲率在六个设置中的 ρ 最大差约.002, 最近邻误差无实质恶化。	删除
30 步积分	3 次粗粒度重求导复现曲率; 一次扰动后的方向对进一步复现有效近邻。	删除
原始两点梯度差	六个设置的 ρ 仅约.10-.28; 梯度幅值遮蔽了方向变化。	拒绝
公平一点单位方向	ρ 达.627-.853, 但在相似度尾部出现高 fitness 差碰撞。	只作第一半
Fisher 与欧氏两点	Fisher 版在六个设置中 ρ 一致持平或小幅提高, 且不增加求导次数或误跳过率; 同时给出坐标不变的长度与跨点对齐。	保留轻量 Fisher
候选级自适应弧长	固定 forward/reverse KL 或 ESS 改变解回的 Fisher 弧长 CV 不超过 .002, 与固定 .03 的描述符指标相同; max-log 和 turning 自适应也无稳定收益。	删除自适应
scratch/warm 双锚点	单个 warm checkpoint bank 同时预测 scratch 与 warm 标签, 且 scratch ρ 约.80、外部 ρ 约.71。	删除双锚点
初始 Gram	与逐 probe 单位方向的距离相关约.98-.995, 且继承相同危险碰撞。	删除
随机投影	可近似保留旧曲率, 但只是在压缩冗余高维坐标, 没有新增机制。	删除

6.4 弧长与探针选择

$\ell \in \{0.01, 0.03, 0.10\}$ 时, Fisher 两点方向对的 ρ 基本稳定。0.01 在匹配集合上偶尔使第二点离第一点太近, 方向分辨率不足; 0.10 没有稳定增益, 且在一个 scratch 设置中使误跳过率轻微恶化。因此当前固定 $\ell = 0.03$, 不把弧长作为候选级超参数。

这里要区分“度量不变”与“步长自动唯一”。Fisher 度量在整体常数外由不变性确定, 但它不会单独决定应走多远。我们固定度量的尺度为 1, 再固定一个对所有候选相同的短弧 0.03。这使候选间比较公平, 也避免为了选步长又引入一组与候选相关的新规则。额外实验中, 用相同的 forward KL、reverse KL 或 ESS 改变反解弧长时, 各候选得到的弧长几乎都是 0.03; 而用最大 log-ratio 或方向转角调节弧长没有稳定提高筛选指标。因此固定短弧是实验与简洁性共同支持的最小选择。

两组独立 bank 的结论相近, 说明描述符不是依赖单次 rollout 噪声的偶然现象。部署时只保留一组由 checkpoint-135 生成的 $R = 8$ 个实例; 第二组仅作为实验复核, 不需要融合尺度或投票。

7 搜索空间覆盖与程序合法性

方法能否找到有效目标，取决于 f 与 g 的 DSL 是否覆盖已知偏好结构，而不取决于描述符公式本身。最低覆盖要求是：

- f 能表达 log-sigmoid、差值、缩放、截断与基本集合归一化，例如

$$f_{\text{pair}}(\Delta p) = -\log \text{sigmoid}(\beta \Delta p);$$

- g 能表达全体有序对、最好样本锚定、top- K /rank 选择，以及依赖目标值差或目标值比的非负权重；
- f 和 g 的所有保护算子在两次 probe 上都必须返回有限标量、有限梯度与非空有效偏好对。

这使程序对能够覆盖常见的成对偏好目标，以及“最佳轨迹作锚点、目标尺度控制权重”的组合优化偏好目标。搜索前应运行可执行资格测试，而不是只靠语法检查：随机生成合法输入，检查输出有限性、梯度非零率、交换正负样本时的响应，以及极端目标尺度下是否触发保护边界。

8 计算代价

设每个实例有 M 条轨迹，程序 g 产生 K 个偏好对，候选表达式一次前后向代价记为 $B(M, K)$ 。最终描述符对每个实例恰好计算两次候选损失，加上线性代价的几何操作，总代价为

$$O(2RB(M, K) + RM).$$

其中 Fisher 单位化、指数映射和平行移动都只含逐元运算与向量内积。它不进行网络的前向或反向传播，不更新参数，不重新 rollout，也不存储 $M \times M$ Fisher 矩阵或 Hessian。

旧版若以 H 个积分步重算候选场，代价约为 $O(RHB)$ ，另有多个对数映射、多次平行移动和多锚点开销。在当前 $H = 30$ 且双锚点的实现中，删减后的候选求导次数从量级 $60R$ 降为 $2R$ ；这是结构性降本，而不只是常数优化。

9 实现边界与失败保护

1. **固定支持**：描述符只能观察参考 bank 已覆盖的轨迹；它无法发现候选在全新状态上的差异。解决方式是保留审计率，并周期性更新整个 bank，而不是为每个候选单独 rollout。
2. **虚拟分布可实现性**：式 (2) 不保证存在网络参数精确实现 q_1 。因此它是局部压力测试，不是参数训练的无偏估计，也无需声称使用重要性采样即可替代训练。
3. **经验流形的边界**：Fisher 度量的唯一性适用于本文选定的有限支持概率单纯形，它不把 q 自动变成共享参数策略的完整流形。
4. **固定弧长的含义**：不变度量确定了如何测量，但不唯一确定 ℓ 。0.03 是对所有候选公用并经消融选定的短弧，不声称等于某个真实优化器的参数步。

5. **数值边界**: 若 $s_C(q)$ 太小、任一 q_m 接近数值下溢、配对为空或产生非有限值, 候选不能因“距离近”而被跳过; 应直接送入审计或判为非法程序。
6. **描述符不是价值**: 大距离只表示行为新, 不表示性能好; 父代选择与最终排名只使用真实 fitness。
7. **g 变化的证据仍不足**: 当前最小化消融主要来自固定参考 g 、变化 f 的历史候选。联合搜索上线前必须单独报告只变 f 、只变 g 、两者都变三组的近邻可靠性。
8. **最终搜索证据**: 离线相关和误跳过率只能证明筛选器有信号; 论文主实验仍应比较相同真实训练预算下的 best-so-far、有效候选数与审计漏失。

10 符号表

符号	含义
$C = (f, g)$	完整程序对; f 生成逐对损失, g 生成偏好对与权重
R, M, K	probe 实例数、每实例轨迹数、程序 g 生成的偏好对数
p_m^0, o_m	第 m 条参考轨迹的 log-probability 与任务目标值
z, q, h	经验 log-weight、其 softmax 概率与平方根坐标 $h = \sqrt{q}$
$\mathcal{L}_C(q)$	在当前经验分布下由完整程序对产生的加权损失
c, u, d	负 log-probability 梯度、Fisher 负自然梯度、其平方根球面单位方向
ℓ	一次自诱导 Fisher-Rao 弧长, 对所有候选固定为 0.03
$\Psi(C)$	所有实例的 $[d_0 \parallel d_1]$ 拼接描述符
$D(C_a, C_b)$	两个程序对的描述符欧氏距离
$F(C)$	真实 on-policy 训练得到的 fitness
τ, T	软筛选的距离中心与温度
$\varepsilon_{\text{audit}}$	即使极近也保留的最小真实训练概率

11 结论

最小化后的 RFPS 不再依赖“黎曼曲率”叙事, 但保留了 Fisher 度量的不变性。完整程序对在固定 rollout 上的 **Fisher 单位自然梯度** 提供主要全局行为信号, 而沿该方向走固定短弧后、再平行移回的**第二个单位方向**能减少危险的局部碰撞。因此最终方法只需要一个参考 bank、两次候选损失求导、一次闭式指数映射和一次闭式平行移动。

这个版本的核心贡献不是发明新几何, 而是把标准 Fisher 几何压缩成一个两点、固定弧长、无积分的行为签名, 将两个相互作用的短程序放进同一个可审计行为表型中, 并用它谨慎分配昂贵的真实训练预算。

参考文献

- [1] Hồng Vân Lê. The uniqueness of the fisher metric as information metric. *arXiv preprint arXiv:1306.1465*, 2013.
- [2] Hao Li, Tianwen Fu, Jifeng Dai, Hongsheng Li, Gao Huang, and Xizhou Zhu. Autoloss-zero: Searching loss functions from scratch for generic tasks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1009–1018, June 2022.
- [3] John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In Francis Bach and David Blei, editors, *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *Proceedings of Machine Learning Research*, pages 1889–1897. PMLR, 2015.